

Análise de Preços de Voos com Base em Datas e Eventos: Um Pipeline para Planejamento de Viagens

Marcos Vinícius de Moraes, Paulo Roberto Vieira, Patrick Fernandes Marins

Instituto de Informática – Universidade Federal de Goiás (UFG)
Campus Samambaia – Caixa Postal 131 – 74.690-900 – Goiânia – GO – Brasil

Resumo. *Este artigo apresenta o desenvolvimento de um pipeline analítico para coleta, transformação e integração de dados abertos e semiestruturados sobre tarifas aéreas no Brasil. O objetivo é identificar padrões de variação de preços em função de datas sazonais, eventos fixos (feriados e férias escolares) e eventos imprevisíveis (pandemias e instabilidades econômicas). Utilizando dados da ANAC e preços extraídos da Latam via automação, propõe-se um modelo analítico que busca compreender o comportamento do mercado aéreo e oferecer subsídios para planejamento de viagens. A pesquisa contribui com uma metodologia replicável e escalável de integração de dados públicos e privados, visando à construção de datasets preditivos.*

1. Introdução e Motivação

O transporte aéreo é um componente estratégico para a mobilidade e o desenvolvimento socioeconômico do Brasil, país com dimensões continentais e elevado índice de deslocamentos inter-regionais. A variabilidade dos preços de passagens aéreas, porém, impõe desafios tanto para o consumidor quanto para planejadores públicos e agentes do setor privado. Compreender a lógica por trás dessa flutuação é fundamental para promover acessibilidade, planejamento inteligente de viagens e formulação de políticas públicas eficientes.

Com a ascensão da cultura data-driven e da disponibilidade crescente de dados públicos — como os disponibilizados pela Agência Nacional de Aviação Civil (ANAC) — e o avanço de técnicas de coleta automatizada de dados (como o web scraping), abre-se uma janela de oportunidade para analisar, com maior granularidade, os padrões de precificação aérea. Isso permite não apenas entender o comportamento do setor, mas também antecipar tendências, otimizar decisões e propor intervenções orientadas por dados.

O presente trabalho propõe uma abordagem analítica que combina diferentes fontes de dados — institucionais e privados — para mapear os principais determinantes da precificação de voos domésticos no Brasil. A proposta é construir um pipeline que vai da coleta de dados à análise estatística, com foco em sazonalidades, ocupação histórica e datas críticas. Tais análises são relevantes para consumidores finais, pesquisadores, gestores públicos e plataformas de turismo.

As premissas do estudo incluem:

- Identificar os principais destinos turísticos nacionais e períodos com maior intensidade de tráfego aéreo;
- Analisar a correlação entre demanda histórica e precificação atual das passagens aéreas;

- Avaliar o impacto de datas sazonais e eventos no comportamento dos preços;
- Propor uma metodologia robusta, escalável e replicável para análise e predição de tarifas.

2. Fundamentação Teórica

A precificação no setor aéreo é amplamente reconhecida como um problema complexo e multifatorial. Companhias aéreas operam com sistemas de gerenciamento de receita baseados em algoritmos de precificação dinâmica, que ajustam tarifas conforme a demanda prevista, ocupação do voo, concorrência e outras variáveis [4]. Essa prática, conhecida como *Revenue Management*, visa maximizar o lucro por assento oferecido.

Estudos como o de Balcombe et al. [1] destacam que a elasticidade da demanda no setor aéreo é fortemente impactada por fatores sazonais e culturais, como férias escolares, feriados prolongados e grandes eventos. Já Hübner e Ognibene [2] abordam a aplicação de técnicas de mineração de dados e aprendizado de máquina para prever a variação de preços, considerando dados históricos de ocupação, dia da semana, antecedência da compra e comportamento do consumidor.

A modelagem preditiva de preços, conforme Zhao et al. [3], enfrenta desafios como a volatilidade dos dados, a dependência de variáveis externas (ex: câmbio, preço do petróleo) e a limitação de acesso a dados transacionais de alta qualidade. Por isso, a integração entre bases heterogêneas é um desafio técnico relevante, demandando normalização, tratamento de ruído e estratégias de enriquecimento de dados.

O presente estudo considera:

- **Dados abertos da ANAC**, que oferecem uma visão institucional e macroestrutural do setor aéreo, com foco em oferta (assentos) e demanda (passageiros pagos);
- **Dados transacionais da Latam**, coletados via scraping, que revelam os preços reais ofertados em datas específicas, com granularidade diária;

A escassez de trabalhos que integram essas duas perspectivas — histórica/mensal versus diária e transacional — representa uma lacuna na literatura. Nossa proposta visa superar esse gap ao propor uma pipeline de análise multigranular que permite estudar correlações entre fatores de ocupação histórica e tarifas ofertadas em tempo real.

3. Método

O pipeline proposto neste trabalho segue uma arquitetura modular com três etapas principais: (1) coleta e transformação de dados da ANAC; (2) extração automatizada de preços reais a partir do site da Latam; e (3) integração e análise exploratória das bases. A Figura 1 apresenta uma visão geral do fluxo de dados implementado.




Figure 1. Arquitetura do pipeline de análise: da coleta à integração e análise exploratória.

3.1. Coleta e Transformação dos Dados - ANAC

A base da ANAC foi obtida a partir do portal de dados abertos do Governo Federal, contendo registros mensais agregados por aeroporto, natureza do voo e tipo de operação.

As etapas de tratamento incluíram:

- Filtragem de voos domésticos, descartando voos internacionais;
- Seleção de voos regulares, com exclusão de operações não regulares e improdutivas;
- Agregação de dados por mês, origem e destino, com foco em passageiros pagos, assentos ofertados e fator de ocupação;
- Conversão de códigos ICAO (4 letras) para IATA (3 letras), usados comercialmente.

Esse processo gerou uma base consolidada com os principais fluxos aéreos do país, permitindo posterior associação com os preços reais coletados no site da companhia aérea.

3.2. Coleta e Transformação de Dados - Latam

A coleta de preços foi realizada com técnicas de *web scraping* utilizando Selenium Web-Driver e Selenium Wire, que permite interceptar requisições HTTP e extrair dados diretamente da API da Latam. O processo incluiu:

- Geração automática de URLs com origem, destino e data (com ênfase em 30 a 90 dias no futuro);
- Interceptação de requisições JSON contendo informações detalhadas sobre voos e preços;
- Armazenamento dos dados em formatos estruturados (JSON/CSV), incluindo hora da consulta, valor mínimo, tipo de tarifa, número de escalas e horário do voo;
- Agendamento dos scrapers para execução contínua com rotação de datas e destinos.

Foram coletados mais de 10.000 registros únicos com granularidade diária, permitindo analisar variações conforme o dia da semana, antecedência de compra e sazonalidade.

3.3. Integração e Análise

A etapa de integração entre as bases exigiu pré-processamento rigoroso para garantir consistência. As etapas incluíram:

- Normalização dos campos de data (formato ISO 8601), tipos numéricos e identificadores de aeroportos;
- Criação de um dicionário de mapeamento entre códigos ICAO (ANAC) e IATA (Latam);
- Junção (merge) com base em: código IATA, mês de referência e trecho (origem-destino);
- Cálculo de estatísticas descritivas (média, desvio padrão, mediana) por faixa temporal;
- Aplicação de correlações de Pearson (linear) e Spearman (monotônica) entre o fator de ocupação da ANAC e o menor preço da Latam;
- Geração de visualizações com bibliotecas Python como Matplotlib e Seaborn.

4. Resultados e Discussões

Os resultados evidenciam padrões consistentes de sazonalidade no mercado aéreo brasileiro. Trechos turísticos como Rio de Janeiro (GIG), Salvador (SSA), Recife (REC) e Florianópolis (FLN) mostraram picos de preços nos meses de janeiro, julho e dezembro — em sincronia com férias escolares e feriados prolongados.

A Figura 2 apresenta a variação média dos preços para o trecho GRU–SSA ao longo do ano, evidenciando flutuações acentuadas em datas comemorativas.




Figure 2. Variação média de preços (Latam) para o trecho GRU–SSA em 2023.

A análise de correlação revelou uma associação estatisticamente significativa entre o fator de ocupação médio da ANAC e o menor preço encontrado na Latam (coeficiente de Pearson = 0,72, $p < 0,01$). Isso confirma a hipótese de que a alta ocupação histórica impacta diretamente a precificação atual.

Outros achados relevantes:

- Voos com menos de 10 dias de antecedência apresentaram, em média, preços 35% maiores;
- Sextas-feiras e domingos concentram os maiores preços médios semanais;
- Algumas rotas apresentaram comportamento anômalo, com preços baixos mesmo em períodos de alta ocupação, sugerindo influência de promoções ou subsídios.

Esses resultados oferecem insights relevantes para sistemas de recomendação de passagens, plataformas de turismo e consumidores que desejam otimizar sua estratégia de compra.

5. Reflexões Éticas e Limitações

5.1. Licenças e Legalidade

A coleta de dados seguiu as seguintes premissas:

- Dados da ANAC são públicos e utilizáveis sob a Política Nacional de Dados Abertos;
- O scraping realizado no site da Latam não violou mecanismos de autenticação, nem tentou burlar paywalls ou sistemas de proteção de acesso, mas desrespeitou as diretrizes estabelecidas no arquivo `robots.txt`, o que pode ser interpretado como uma infração às boas práticas recomendadas na web. No entanto, é importante destacar que a coleta foi feita exclusivamente para fins acadêmicos, em pequena escala, sem causar sobrecarga nos servidores da empresa. Além disso, os dados foram usados exclusivamente para fins acadêmicos, sem redistribuição pública ou comercial;

Há um debate ético legítimo sobre o uso de scraping para fins de pesquisa, especialmente quando envolve dados comerciais. É necessário ponderar o valor científico da análise contra os limites da legalidade e da privacidade digital.

5.2. Privacidade e LGPD

- Nenhum dado pessoal foi coletado, processado ou armazenado;
- As informações extraídas são públicas, anonimizada e agregadas;
- O projeto está em conformidade com os princípios da LGPD, respeitando a minimização de dados e finalidade específica.

5.3. Limitações do Estudo

- A amostra de preços foi restrita à companhia Latam e ao período da coleta, limitando a generalização;
- O scraping pode sofrer falhas devido à alterações na estrutura do site da Latam;
- Dados da ANAC são agregados mensalmente, o que pode mascarar variações intra-mensais importantes;
- Fatores exógenos como crises econômicas, eventos climáticos e políticas governamentais não foram incorporados na análise;
- O impacto da concorrência entre companhias e promoções não foi explorado.

Essas limitações abrem espaço para futuras pesquisas e melhorias na metodologia.

6. Conclusão e Trabalhos Futuros

Este estudo demonstrou a viabilidade e relevância da integração de dados públicos e privados para análise da dinâmica de preços de passagens aéreas no Brasil. A metodologia proposta permitiu identificar padrões de sazonalidade, correlações entre ocupação histórica e preços atuais, e impacto de datas específicas e dias da semana na precificação.

Essas descobertas podem auxiliar consumidores a otimizar a compra de passagens, gestores públicos no planejamento de infraestruturas e agências de viagem no desenvolvimento de soluções inteligentes.

Para trabalhos futuros, destacam-se:

- Expansão da coleta para outras companhias (Gol, Azul) para maior abrangência do mercado;
- Integração de variáveis climáticas, econômicas e políticas para enriquecer modelos preditivos;
- Desenvolvimento de modelos de aprendizado de máquina para predição de preços em tempo real;
- Criação de dashboards interativos para visualização dinâmica dos dados;
- Avaliação do impacto de políticas públicas na acessibilidade e competição regional no setor aéreo.

7. Dados Oficiais da Latam e Estratégia de Coleta

Apesar da Latam não disponibilizar diretamente bases públicas estruturadas de preços históricos, os dados sobre tarifas e voos estão acessíveis em seu site oficial (<https://www.latam.com/>). Para capturar esses dados em alta granularidade, foi utilizada uma estratégia de *web scraping* automatizado por meio de Selenium WebDriver e Selenium Wire, que permite interceptar as requisições de API feitas pelo navegador durante a navegação.

Essa técnica possibilita extrair informações em tempo real sobre preços, horários e disponibilidade para diversos trechos e datas, aproximando-se dos dados transacionais do sistema da companhia. Embora essa coleta não seja oficial no sentido de distribuição formal, é uma forma legítima de acessar dados públicos disponíveis ao consumidor final.

Além disso, os dados oficiais da Latam em forma consolidada, como relatórios financeiros e estatísticas de tráfego, podem ser encontrados em suas publicações institucionais e comunicados à imprensa, porém não contemplam o detalhamento temporal e tarifário necessário para esta análise. Por isso, a combinação de dados públicos governamentais (ANAC) com dados extraídos do site Latam enriquece a análise ao combinar oferta, demanda e precificação em múltiplas granularidades.

References

- [1] Balcombe, K., Fraser, I., and Harris, L. (2009). *Consumer preferences for air travel attributes*. Transportation Research Part E: Logistics and Transportation Review, 45(3), 352-361.
- [2] Hübner, G., and Ognibene, D. (2020). *Airfare prediction using machine learning: A review and future directions*. Journal of Air Transport Management, 87, 101844.
- [3] Zhao, J., Yang, Y., and Wu, Y. (2021). *Data-driven airfare prediction with dynamic factors*. Transportation Research Part C: Emerging Technologies, 125, 103061.
- [4] Phillips, R. (2005). *Pricing and Revenue Optimization*. Stanford University Press.